

**Département d'informatique****IFT 704 — *Apprentissage automatique à grande échelle*****Plan d'activité pédagogique
Hiver 2026**

Personne enseignante :Toby Dylan HOCKING

Courriel : Toby.Dylan.Hocking@USherbrooke.ca

Local : D4-1010-11

Téléphone : 819-821-8000 (65565)

Site : <https://github.com/tdhock/2026-01-aa-grande-echelle>Disponibilité : Prise de rendez-vous par courriel

Horaire :lundi 16h30/17h30, vendredi 9h30/11h30

Description officielle de l'activité pédagogique¹

Cibles de formation :	Approfondir les bonnes pratiques en lien avec l'utilisation et le développement des logiciels d'apprentissage automatique. S'initier aux calculs parallèles pour l'apprentissage automatique.
Contenu :	Rappel de concepts fondamentaux en apprentissage automatique. Bibliothèques informatiques en IA et logiciel libre, reproductibilité, DevOps, MLOps, calcul massivement parallèle en apprentissage automatique, intégration et livraison en continu. Ce cours se concentre sur les meilleures pratiques liées au développement et à l'utilisation d'algorithmes d'apprentissage automatique à grande échelle, en s'appuyant sur le logiciel libre et les calculs parallèles. Dans le cadre du volet logiciel libre, nous explorerons le développement d'IA sous l'angle de différents langages de programmation, en abordant la création et la diffusion de bibliothèques logicielles, ainsi que la contribution à des projets logiciels libres existants. Le volet consacré au calcul à grande échelle couvrira les concepts liés aux grappes de calcul, à l'exécution parallèle de la descente de gradient (sur CPU et GPU), ainsi que les outils et services dédiés au stockage et à la diffusion des résultats d'entraînement.
Crédits	3
Organisation	3 heures d'exposé magistral par semaine 0 heure d'exercices par semaine 6 heures de travail personnel par semaine
Préalable(s)	IFT 603 ou l'équivalent
Particularités	Aucune

¹ <https://www.usherbrooke.ca/admission/fiches-cours/IFT704/>

1 Présentation

Cette section présente les objectifs spécifiques et le contenu détaillé de l'activité pédagogique. Cette section, non modifiable sans l'approbation d'un comité de programme du Département d'informatique, constitue la version officielle.

1.1 Mise en contexte

L'apprentissage automatique comprend les algorithmes pour exploiter les grands jeux de données. Ce cours a deux volets : développement des logiciels libres, et le calcul en parallèle.

Dans un projet d'apprentissage artificiel, on utilise différents logiciels libres (python, R, torch, etc), car il existe certaines fonctions uniquement dans certaines bibliothèques (par exemple, validation croisée en parallèle avec mlr3 dans R). Quand il y a des fonctions qui manquent dans les logiciels existants, il est possible de contribuer à un logiciel existant (si la fonctionnalité est souhaitée dans le logiciel), ou bien de créer un nouveau logiciel. Pour contribuer à un logiciel existant, on propose des modifications dans un Pull Request sur GitHub. Pour créer un nouveau logiciel, on met le code et documentation sur GitHub, avec des tests qui tournent après chaque mise à jour du code, grâce à l'intégration en continu. Pour l'implémentation efficace de certains algorithmes, il faut utiliser des codes à bas niveau (C et C++), idéalement avec interface qui marche avec différents codes à haut niveau (R et python).

Pour apprendre des modèles avec grand nombre de paramètres, sur les grands jeux de données, le calcul en parallèle est très pratique. Le volet sur le calcul en parallèle aborde l'utilisation des GPUs (pour les différents paramètres d'un modèle), et des CPUs (pour les différents modèles, hyper-paramètres, jeux de données, divisions en validation croisée). Dans l'utilisation de CPUs en parallèle, on discutera comment faire dans les grappes de calcul (ex : SLURM), dans C++ (OpenMP), dans python (multiprocessing), et dans R (future/mirai).

1.2 Cibles de formation spécifiques (Objectifs)

À la fin de cette activité pédagogique, l'étudiante ou l'étudiant sera capable :

1. Créer un projet de logiciel libre, avec documentation et tests ;
2. Contribuer à un logiciel libre, avec un Pull Request sur GitHub ;
3. Créer des codes pour l'apprentissage et la prédiction efficace, par exemple avec C++ et interface R et Python
4. Réaliser la validation croisée en parallèle, sur différents algorithmes et jeux de données, grâce aux grappes de calcul
5. Calculer les paramètres d'un réseau de neurones en parallèle grâce aux GPUs ;

1.3 Contenu détaillé

Thème	Contenu	Heures	Lectures suggérées	Objectifs
1	Organiser des projets de logiciel libre et de recherche reproductible	5	The Turing Way Guide for Reproducible Research	1
2	Programmation python, API C pour des tableaux numpy,	5	Machine Learning avec scikit-learn (Géron), NumPy C-API Manual,	2

	création de progiciel python		NumPy Essentials Chapter 9 (Chin et al)	
3	Programmation R, API R et cpp pour tableaux, création de progiciel R	5	R Packages (Wickham and Bryan), Rcpp for Everyone (Tsuda), Seamless R and C++ Integration with Rcpp (Eddelbuettel)	2
4	Utilisation de github : collaboration, intégration et livraison en continu	5	Happy Git and GitHub for the useR (Bryan)	1
5	Utilisation d'une grappe de calcul pour comparer différents algorithmes d'apprentissage sur différents jeux de données	10	Applied Machine Learning Using mlr3 in R, Chapter 11, Large-Scale Benchmarking (Fischer et al)	3
6	Apprentissage artificiel sur carte graphique avec <i>torch/GPU</i>	10	torch.cuda API documentation	3
7	Structures expérimentales pour entraînements distribués	8	Alliance Canada documentation for Ray	3

1. Les heures associées à un thème particulier incluent les heures d'exercices pour un total de 48 heures (douze semaines de quatre heures).

2 Organisation

2.1 Méthode pédagogique

Les heures placées à l'horaire de chaque semaine couvrent les cours et certains exercices, les autres exercices étant faits sur votre temps personnel. La distribution du temps indiquée ci-dessus l'est à titre indicatif seulement. Il ne faut pas craindre de s'attarder sur un sujet mal intégré ni de passer rapidement sur un autre déjà bien compris. Les sujets ne sont pas vus exactement dans l'ordre indiqué. Durant les cours, l'utilisation en classe du cellulaire est prohibée.

La remise des laboratoires se fait toujours par une collecte automatique (par le logiciel WEB *Turnin*), effectuée le vendredi à 23h59. Les dates de remise des devoirs sont spécifiées plus loin.

2.2 Calendrier du cours approximatif

Semaine	Thèmes	TP
1	rappels de python / scikit learn	1
2	bases de R / mlr3	2
3	Apprentissage en parallèle sur grappe de calcul (python)	3
4	apprentissage en parallèle sur grappe de calcul (R)	4
5	validation croisée, comparer entraînement sur différentes sous-ensembles	5
6	Entraînement avec GPU	6
7	Structures expérimentales pour entraînements distribués	
8	Examen intra	
9	Relâche	
10	Organiser et publier un projet de recherche reproductible	
11	Créer package Python	7
12	Créer package R	
13	intégration et livraison en continu	8
14	revision	
15	Examen finaux	
16	Examens finaux	

2.3 Évaluation

Laboratoires : 50 %
 Examen périodique : 20 %
 Examen final : 30 %

Conformément au règlement facultaire d'évaluation des apprentissages², l'enseignant peut retourner à l'étudiante ou à l'étudiant tout travail non conforme aux exigences quant à la qualité de la langue et aux normes de présentation.

Le plagiat consiste à utiliser des résultats obtenus par d'autres personnes afin de les faire passer pour sien et dans le dessein de tromper l'enseignant. Si une preuve de plagiat est attestée, elle sera traitée en conformité, entre autres, avec l'article 9.4.1 du Règlement des études³ de l'Université de Sherbrooke. L'étudiant ou l'étudiante peut s'exposer à de graves sanctions, dont automatiquement une note de zéro (0) au devoir ou à l'examen en question. Ceci n'indique pas que vous n'avez pas le droit de coopérer entre deux équipes tant que la rédaction finale des documents et la création du programme restent le fait de votre équipe. En cas de doute de plagiat, l'enseignant peut demander à l'équipe d'expliquer les notions ou le fonctionnement du code qu'il considère comme étant plagié. En cas de doute, ne pas hésiter à demander conseil et assistance à l'enseignant afin d'éviter toute situation délicate par la suite.

2.4 Échéancier des travaux

TP	Thème	Remise
1	Validation croisée en python	Semaine 2
2	Validation croisée en R	Semaine 3
3	Grappe de calcul avec python	Semaine 4
4	Grappe de calcul avec R	Semaine 5
5	Comparer entraînement sur différentes sous-ensembles	Semaine 6
6	Entraînement avec GPU	Semaine 7
7	Package Python	Semaine 11
8	Package R	Semaine 13

Directives particulières

Les devoirs sont à faire individuellement.

Lors des examens, une page manuscrite sera permise. Aucun appareil électronique ne sera accepté.

2.5 Utilisation d'appareils électroniques et du courriel

Selon le règlement complémentaire des études, section 4.2.3⁴, l'utilisation d'ordinateurs, de cellulaires ou de tablettes pendant une prestation est interdite à condition que leur usage soit explicitement permis dans le plan de cours.

Dans ce cours le règlement 4.2.3 s'applique à moins d'avoir obtenu personnellement l'autorisation du professeur. Cette permission peut être retirée en tout temps, si l'appareil n'est pas utilisé uniquement à des fins d'apprentissage.

Comme indiqué dans le règlement universitaire des études, section 4.2.3⁵, toute utilisation d'appareils de captation de la voix ou de l'image exige la permission du professeur.

Note : L'utilisation du courrier électronique est recommandée pour poser vos questions.

3 Matériel pour le cours

² https://www.usherbrooke.ca/sciences/fileadmin/sites/sciences/Etudiants_actuels/Informations_academiques_et_reglements/2017-10-27_Reglement_facultaire_-_evaluation_des_apprentissages.pdf

³ <https://www.usherbrooke.ca/registraire/droits-et-responsabilites/reglement-des-etudes/>

⁴ https://www.usherbrooke.ca/sciences/fileadmin/sites/sciences/documents/Intranet/Informations_academiques/Sciences_Reglement_complementaire_2017-05-09.pdf

⁵ <https://www.usherbrooke.ca/registraire/droits-et-responsabilites/reglement-des-etudes/>

Les diapos du cours sont disponibles sur le site web du cours.

Les devoirs du cours sont conçu pour fonctionner sous Unix. Vous pouvez développer dans l'environnement de votre choix, mais votre programme doit pouvoir fonctionner sous Unix.

4 Documentation et références

- The Turing Way Guide for Reproducible Research <https://book.the-turing-way.org/reproducible-research/reproducible-research>
- Machine Learning avec scikit-learn (Géron), 3è édition, Dunod (2023).
- NumPy C-API Manual <https://numpy.org/doc/stable/reference/c-api/index.html>
- R Packages (Wickham and Bryan), Oreilly (2023). <https://r-pkgs.org/>
- Rcpp for Everyone (Tsuda) https://teuder.github.io/rcpp4everyone_en/
- Seamless R and C++ Integration with Rcpp (Eddelbuettel), Springer (2013).
- Happy Git and GitHub for the useR (Bryan) <https://happygitwithr.com/>
- Applied Machine Learning Using mlr3 in R, Chapter 11, Large-Scale Benchmarking (Fischer et al), Taylor and Francis (2024). https://mlr3book.mlr-org.com/chapters/chapter11/large-scale_benchmarking.html
- torch.cuda API documentation <https://docs.pytorch.org/docs/stable/cuda.html>
- Alliance Canada documentation for Ray <https://docs.alliancecan.ca/wiki/Ray>



L'intégrité intellectuelle passe, notamment, par la reconnaissance des sources utilisées. À l'Université de Sherbrooke, on y veille!

Extrait du Règlement des études (Règlement 2575-009)

9.4.1 DÉLITS RELATIFS AUX ÉTUDES

Un délit relatif aux études désigne tout acte trompeur ou toute tentative de commettre un tel acte, quant au rendement scolaire ou une exigence relative à une activité pédagogique, à un programme ou à un parcours libre.

Sont notamment considérés comme un délit relatif aux études les faits suivants :

- a) commettre un plagiat, soit faire passer ou tenter de faire passer pour sien, dans une production évaluée, le travail d'une autre personne ou des passages ou des idées tirés de l'œuvre d'autrui (ce qui inclut notamment le fait de ne pas indiquer la source d'une production, d'un passage ou d'une idée tirée de l'œuvre d'autrui);
 - b) commettre un autoplagiat, soit soumettre, sans autorisation préalable, une même production, en tout ou en partie, à plus d'une activité pédagogique ou dans une même activité pédagogique (notamment en cas de reprise);
 - c) usurper l'identité d'une autre personne ou procéder à une substitution de personne lors d'une production évaluée ou de toute autre prestation obligatoire;
 - d) fournir ou obtenir toute aide non autorisée, qu'elle soit collective ou individuelle, pour une production faisant l'objet d'une évaluation;
 - e) obtenir par vol ou toute autre manœuvre frauduleuse, posséder ou utiliser du matériel de toute forme (incluant le numérique) non autorisé avant ou pendant une production faisant l'objet d'une évaluation;
 - f) copier, contrefaire ou falsifier un document pour l'évaluation d'une activité pédagogique;
- [...]

Par plagiat, on entend notamment :

- Copier intégralement une phrase ou un passage d'un livre, d'un article de journal ou de revue, d'une page Web ou de tout autre document en omettant d'en mentionner la source ou de le mettre entre guillemets;
- reproduire des présentations, des dessins, des photographies, des graphiques, des données... sans en préciser la provenance et, dans certains cas, sans en avoir obtenu la permission de reproduire;
- utiliser, en tout ou en partie, du matériel sonore, graphique ou visuel, des pages Internet, du code de programme informatique ou des éléments de logiciel, des données ou résultats d'expérimentation ou toute autre information en provenance d'autrui en le faisant passer pour sien ou sans en citer les sources;
- résumer ou paraphraser l'idée d'un auteur sans en indiquer la source;
- traduire en partie ou en totalité un texte en omettant d'en mentionner la source ou de le mettre entre guillemets ;
- utiliser le travail d'un autre et le présenter comme sien (et ce, même si cette personne a donné son accord);
- acheter un travail sur le Web ou ailleurs et le faire passer pour sien;
- utiliser sans autorisation le même travail pour deux activités différentes (autoplagiat).

Autrement dit : mentionnez vos sources
